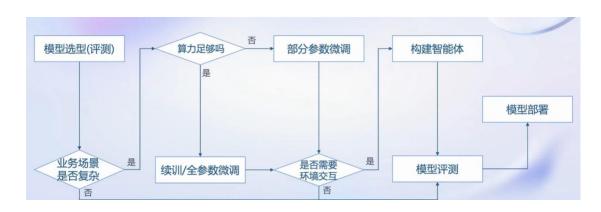
第一节课笔记 by 纪佳翼

1. 概览:第一节课介绍了书生·浦语大模型全链路开源体系,这是一个基于大规模预训练语言模型的中文自然语言处理平台,涵盖了数据、预训练、微调、评测、部署和智能体等多个环节,旨在为广大开发者和研究者提供一个完整、高效、易用的工具集,以促进中文自然语言处理的发展和应用。





2.数据:书生·浦语大模型使用了万卷数据集作为预训练的数据来源,这是一个包含文本、图像和视频等多模态数据的大规模中文语料库,涵盖了科技、文学、媒体、教育和法律等多个领域。2该数据集对模型的知识内容、逻辑推理和泛化能力的提升有显著效果。同时,该数据集也注重与主流中国价值观进行对齐,并通过算法和人工评估的结合提高语料库的纯净度。

3. 预训练:



4.微调:书生·浦语大模型提供了多种微调的方式和场景,以适应不同的需求和应用。其中,增量续训是一种在原有模型的基础上,增加少量领域相关的数据进行训练的方法,可以让模型学习到更多的知识和技能,或者适应特定的风格和语境。有监督微调是一种使用高质量的对话、问答等数据进行训练的方法,可以让模型学会理解和遵循各种指令,或者注入少量领域知识。书生·浦语大模型还开源了多个微调后的模型,供开发者和研究者参考和使用。



5.评测:书生·浦语大模型使用了多个公开的中英文自然语言处理评测数据集和指标,以客观地衡量模型的性能和效果。其中,中文评测数据集包括 CLUE、CCKS、CMRC等,英文评测数据集包括 GLUE、SQuAD、SuperGLUE等。书生·浦语大模型在这些评测数据集上都取得了不错的成绩,显示了其强大的自然语言处理能力。

| 国内外评测体系的整体态势 | | | | | | |
|--------------|---------------------|---|-----------------------------------|---------------------|------------------------|------------------------|
| | ≵HELM | FlagEval | MMLU | Alpaca Eval | SuperCLUE 中文大概宣信合性無序基章 | OpenLLM Leaderboard |
| 机构 | Stanford University | 北京智源人工智能研究院 BELING ACADEMY OF ARTHYCIAL INTELLIGENCE | Berkeley UNIVERSITY OF CALIFORNIA | Stanford University | CLUE | Hugging Face |
| 类型 | 客观评测 | 客观/主观评测 | 客观评测 | 主观评测 | 客观/主观评测 | 客观评测 |
| 量级 | 5W+ 英文题目 | 8W+ 中英双语 | 1W+ 英文题目 | 1K+ 英文题目 | 3K+ 中文题目 | 2W+ 英文题目 |

6.部署:书生·浦语大模型支持多种部署方式和平台,以满足不同的需求和场景。其中,云端部署是一种通过云服务提供模型的访问和使用的方式,可以实现高效、稳定、安全的模型服务。边缘部署是一种在本地设备上运行模型的方式,可以实现低延迟、低成本、隐私保护的模型应用。

7.智能体:书生·浦语大模型还提供了多种智能体的应用和示例,以展示模型的多样性和创造力。其中,智能体是一种基于模型的交互式应用,可以让模型与用户进行自然语言的对话和交流,或者完成一些特定的任务和目标。书生·浦语大模型的智能体包括了多个领域和场景,如教育、娱乐、医疗、法律等,为用户提供了丰富的体验和服务。